

Akademische Arbeit #12: Maschinelles Lernen und Verifikation

Zusammenfassung

Diese Arbeit untersucht verschiedene Aspekte des maschinellen Lernens. Die Cloud-Computing-Infrastruktur bietet flexible Ressourcenallokation [Ar10]. Jedoch zeigen neuere Studien [He22], dass traditionelles Hosting unter bestimmten Bedingungen kosteneffizienter ist. Der Stand der Forschung [Fl25] deutet auf eine Hybrid-Strategie hin.

1 Einleitung

Die Verifikation von Referenzen ist ein kritischer Aspekt der wissenschaftlichen Forschung [Ar21]. Laut aktuellen Studien [He20] können fehlerhafte Referenzen die Integrität gefährden [Fl23]. Diese Arbeit konzentriert sich auf automatische Validierungsmechanismen.

2 Methoden

Wir verwenden ein mehrstufiges Verifikationssystem [Bi97] zur Überprüfung von Referenzen. Der Prozess beinhaltet: (1) Datenextraktion [VB22], (2) Metadaten-Validierung [We15]. Besondere Aufmerksamkeit wird auf Deutsche Umlaute gelegt.

3 Ergebnisse

Unsere Versuche zeigen, dass korrekte Referenzen zu 99% erkannt werden [Ar21]. Halluzinierte Referenzen werden zu 98% als solche identifiziert [He20]. Metadaten-Inkonsistenzen werden mit 95% Genauigkeit erkannt.

Literaturverzeichnis

- [Ar21] Garcia, L.: On the Complexity of Neural Networks. In: arXiv preprint, 2021. <https://doi.org/10.1145/3468754.3468769>.
- [He20] Taylor, M.: Scalability of Distributed Systems. In: IEEE Distributed Systems, 2020.
- [Fl23] PyTorch Team: PyTorch Documentation and Tutorials, 2023.
- [Bi97] Hochreiter, S., & Schmidhuber, J.: Long Short-Term Memory. In: Neural Computation 9, S. 1735-1780, 1997. <https://doi.org/10.1162/neco.1997.9.8.1735>.
- [VB22] Garcia, L., & Rodriguez, M.: Unified Theory of Everything Using Neural Networks. In: Proceedings of the Global Symposium on Universal Knowledge, S. 1-15, 2022.
- [We15] Schmidhuber, J.: Deep Learning in Neural Networks: An Overview, 2015.