

Akademische Arbeit #23: Maschinelles Lernen und Verifikation

Zusammenfassung

Diese Arbeit untersucht verschiedene Aspekte des maschinellen Lernens. Die Cloud-Computing-Infrastruktur bietet flexible Ressourcenallokation [Ar10]. Jedoch zeigen neuere Studien [He22], dass traditionelles Hosting unter bestimmten Bedingungen kosteneffizienter ist. Der Stand der Forschung [Fl25] deutet auf eine Hybrid-Strategie hin.

1 Einleitung

Die Verifikation von Referenzen ist ein kritischer Aspekt der wissenschaftlichen Forschung [Ar16]. Laut aktuellen Studien [He23] können fehlerhafte Referenzen die Integrität gefährden [Fl22]. Diese Arbeit konzentriert sich auf automatische Validierungsmechanismen.

2 Methoden

Wir verwenden ein mehrstufiges Verifikationssystem [Bi20] zur Überprüfung von Referenzen. Der Prozess beinhaltet: (1) Datenextraktion [VB21], (2) Metadaten-Validierung [We16]. Besondere Aufmerksamkeit wird auf Deutsche Umlaute gelegt.

3 Ergebnisse

Unsere Versuche zeigen, dass korrekte Referenzen zu 99% erkannt werden [Ar16]. Halluzinierte Referenzen werden zu 98% als solche identifiziert [He23]. Metadaten-Inkonsistenzen werden mit 95% Genauigkeit erkannt.

Literaturverzeichnis

[Ar16] Redmon, J., Divvala, S., Girshick, R., & Farhadi, A.: You Only Look Once: Unified, Real-Time Object Detection. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, S. 779-788, 2016.

[He23] McKinsey & Company: The State of AI in 2023. McKinsey & Company, 2023.
<https://www.mckinsey.com/capabilities/quantumblack/our-insights/the-state-of-ai-in-2023>.

[Fl22] Taylor, M.: Early Insights on Emerging Topics, 2022.

[Bi20] Taylor, M.: Scalability of Distributed Systems. In: IEEE Distributed Systems, 2020.

[VB21] Thompson, M.: Early version: Towards Better Understanding. In: arXiv preprint, 2021.

[We16] Goodfellow, Ian: NIPS 2016 Tutorial: Generative Adversarial Networks, 2016.