

Akademische Arbeit #25: Maschinelles Lernen und Verifikation

Zusammenfassung

Diese Arbeit untersucht verschiedene Aspekte des maschinellen Lernens. Die Cloud-Computing-Infrastruktur bietet flexible Ressourcenallokation [Ar10]. Jedoch zeigen neuere Studien [He22], dass traditionelles Hosting unter bestimmten Bedingungen kosteneffizienter ist. Der Stand der Forschung [Fl25] deutet auf eine Hybrid-Strategie hin.

1 Einleitung

Die Verifikation von Referenzen ist ein kritischer Aspekt der wissenschaftlichen Forschung [Ar16]. Laut aktuellen Studien [He21] können fehlerhafte Referenzen die Integrität gefährden [Fl17]. Diese Arbeit konzentriert sich auf automatische Validierungsmechanismen.

2 Methoden

Wir verwenden ein mehrstufiges Verifikationssystem [Bi18] zur Überprüfung von Referenzen. Der Prozess beinhaltet: (1) Datenextraktion [VB23], (2) Metadaten-Validierung [We14]. Besondere Aufmerksamkeit wird auf Deutsche Umlaute gelegt.

3 Ergebnisse

Unsere Versuche zeigen, dass korrekte Referenzen zu 99% erkannt werden [Ar16]. Halluzinierte Referenzen werden zu 98% als solche identifiziert [He21]. Metadaten-Inkonsistenzen werden mit 95% Genauigkeit erkannt.

Literaturverzeichnis

- [Ar16] Goodfellow, Ian: NIPS 2016 Tutorial: Generative Adversarial Networks, 2016.
- [He21] Juan García-López: Spanish Research in ML. In: IBERIAN NLP, 2021.
- [Fl17] Vaswani Ashish; Shazeer Noam; et al.: Attention is All You Need. In: NIPS, 2017.
<https://doi.org/10.48550/arXiv.1706.03762>.
- [Bi18] Devlin, J. (2018); Chang, M. W.; Lee, K.; Toutanova, K.: BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In: arXiv preprint arXiv:1810.04805, 2018.
- [VB23] Intel: AI Trends and Infrastructure Report 2023. Intel, 2023.
- [We14] Bahdanau, D., Cho, K., & Bengio, Y.: Neural Machine Translation by Jointly Learning to Align and Translate. In: arXiv preprint, 2014.