

Akademische Arbeit #31: Maschinelles Lernen und Verifikation

Zusammenfassung

Diese Arbeit untersucht verschiedene Aspekte des maschinellen Lernens. Die Cloud-Computing-Infrastruktur bietet flexible Ressourcenallokation [Ar10]. Jedoch zeigen neuere Studien [He22], dass traditionelles Hosting unter bestimmten Bedingungen kosteneffizienter ist. Der Stand der Forschung [Fl25] deutet auf eine Hybrid-Strategie hin.

1 Einleitung

Die Verifikation von Referenzen ist ein kritischer Aspekt der wissenschaftlichen Forschung [Ar21]. Laut aktuellen Studien [He17] können fehlerhafte Referenzen die Integrität gefährden [Fl21]. Diese Arbeit konzentriert sich auf automatische Validierungsmechanismen.

2 Methoden

Wir verwenden ein mehrstufiges Verifikationssystem [Bi22] zur Überprüfung von Referenzen. Der Prozess beinhaltet: (1) Datenextraktion [VB22], (2) Metadaten-Validierung [We20]. Besondere Aufmerksamkeit wird auf Deutsche Umlaute gelegt.

3 Ergebnisse

Unsere Versuche zeigen, dass korrekte Referenzen zu 99% erkannt werden [Ar21]. Halluzinierte Referenzen werden zu 98% als solche identifiziert [He17]. Metadaten-Inkonsistenzen werden mit 95% Genauigkeit erkannt.

Literaturverzeichnis

- [Ar21] Davis, R.: Novel Approaches to Distributed Learning, 2021.
- [He17] Bojanowski, P., Grave, E., Joulin, A., & Mikolov, T.: Enriching Word Vectors with Subword Information. In: Transactions of the Association for Computational Linguistics 5, S. 135-146, 2017.
- [Fl21] Anderson, T.: CVPR 2021 - Object Detection Benchmarks. In: CVPR, 2021.
- [Bi22] Taylor, M.: Paper with paywalled URL. In: Science, 2022. <https://doi.org/10.1126/science.abd1234>.
- [VB22] Smith, J.: Deep Learning Advances. In: Journal of ML, 2022. <https://doi.org/10.1234/jml.2022.001>.
- [We20] Chen, S., Wang, X.: Robust Learning with Adversarial Examples. In: NeurIPS, 2020.